ЗВІТ БЕЗКРОВНА МІОД ЛАБ1

Встановлення бібліотек у венв:

python -m pip install pandas numpy matplotlib.pyplot as plt

Запуск проекту:

python miod_lab1.py

1.1 Вибір та завантаження набору даних

https://www.kaggle.com/

Вивід усього датасету

```
Приветствие   Welcome to Settings Sync   miod_lab1.py ×
miod_lab1.py > ...
import pandas as pd
import numpy as np

# 1.1

df = pd.read_csv('job_dataset.csv')
print(df)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
(.venv) A:\уник\4_курс\miod\miod_lab1>python miod_lab1.py
                job_title  experience_years education_level  ...  remote_work certifications  salary
0             AI Engineer                10       Bachelor  ...       Hybrid              2  109413
1            Data Analyst                 5       Bachelor  ...           No              0   93764
2       Frontend Developer               18            PhD  ...           No              1  148123
3         Business Analyst               19            PhD  ...          Yes              0  189123
4          Product Manager               15       Bachelor  ...          Yes              0  165069
...                    ...              ...            ...  ...          ...            ...     ...
249995   Software Engineer               17            PhD  ...           No              1  127791
249996  Frontend Developer               20            PhD  ...           No              2  154593
249997    Business Analyst                1       Bachelor  ...          Yes              0   75988
249998      Data Scientist                0    High School  ...       Hybrid              5   90467
249999        Data Analyst               16        Diploma  ...           No              5  133084

[250000 rows x 10 columns]
```

Використовуючи бібліотеку pandas завантажте набір даних у DataFrame та виведіть перші 5 рядків для перевірки

```
# 1.1
# Завантажуємо набір даних у DataFrame без зміни стандартного індексу
df = pd.read_csv('job_dataset.csv')

# Виводимо перші 5 рядків для перевірки
print("-------------------перші 5 рядків-------------------")
print(df.head())
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
(.venv) A:\уник\4_курс\miod\miod_lab1>python miod_lab1.py
-------------------перші 5 рядків-------------------
            job_title  experience_years education_level  skills_count       industry company_size   location remote_work  certifications  salary
0         AI Engineer                10       Bachelor             2     Healthcare       Medium      India      Hybrid               2  109413
1        Data Analyst                 5       Bachelor            17        Telecom        Small  Australia          No               0   93764
2  Frontend Developer                18            PhD             4          Media       Medium  Singapore          No               1  148123
3    Business Analyst                19            PhD            13         Retail       Medium     Canada         Yes               0  189123
4     Product Manager                15       Bachelor             7  Manufacturing        Large     Sweden         Yes               0  165069
-------------------наші 8 колонок-------------------
                job_title  experience_years education_level  skills_count remote_work  salary company_size  certifications
```

1.2 Очищення набору даних

Видаліть зайві стовпчики, залишивши від 5 до 10 колонок, які будуть необхідні для подальшого аналізу.

Залишили 8 колонок

```
Приветствие   Welcome to Settings Sync   miod_lab1.py ×
miod_lab1.py > ...
print(df)
# Використовуючи бібліотеку pandas завантажте набір даних у DataFrame та виведіть перші 5 рядків для перевірки
print(df.head())

#1.2 Очищення набору даних
#Видаліть зайві стовпчики, залишивши від 5 до 10 колонок, які будуть необхідні для подальшого аналізу.
df = df[['experience_years', 'education_level', 'skills_count', 'remote_work', 'salary', 'company_size', 'certifications']]
print(df)
```

```
ПРОБЛЕМЫ   ВЫХОДНЫЕ ДАННЫЕ   ПОРТЫ   AZURE
ТЕРМИНАЛ                                   Представления и дополнительные действия...

                   experience_years education_level  skills_count remote_work  salary company_size  certifications
job_title
AI Engineer                      10        Bachelor             2      Hybrid  109413       Medium               2
Data Analyst                      5        Bachelor            17          No   93764        Small               0
Frontend Developer               18             PhD             4          No  148123       Medium               1
Business Analyst                 19             PhD            13         Yes  189123       Medium               0
Product Manager                  15        Bachelor             7         Yes  165069        Large               0
...                             ...             ...           ...         ...     ...          ...             ...
Software Engineer                17             PhD             2          No  127791   Enterprise               1
Frontend Developer               20             PhD             7          No  154593      Startup               2
Business Analyst                  1        Bachelor            12         Yes   75988   Enterprise               0
Data Scientist                    0     High School             2      Hybrid   90467        Small               5
Data Analyst                     16         Diploma             2          No  133084       Medium               5

[250000 rows x 7 columns]
```

1.3 Обробка пропущених значень

Оберіть один ключовий стовпчик (наприклад, дату, ідентифікаційний номер, або основну числову метрику) і видаліть з `DataFrame` усі рядки, де це поле містить порожнє значення (`NaN`)

Спочатку пошук що вони є (в нас немає)

print(df.isna().sum())

```
ПРОБЛЕМЫ   ВЫХОДНЫЕ ДАННЫЕ   ПОРТЫ   AZURE
ТЕРМИНАЛ

[250000 rows x 7 columns]
experience_years    0
education_level     0
skills_count        0
remote_work         0
salary              0
company_size        0
certifications      0
dtype: int64
```

1.4 Форматування даних

Спочатку дивимось які в нас типи данних присутні

```
24    print(df.dtypes)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
[250000 rows x 7 columns]
experience_years    int64
education_level       str
skills_count        int64
remote_work           str
salary              int64
company_size          str
certifications      int64
dtype: object

(.venv) A:\уник\4_курс\miod\miod_lab1>
```

```
27    # Перетворюємо колонку remote_work у булевий тип:
28    # Yes -> True, No -> False, Hybrid -> True
29    print("--------------------форматування даних у remote_work--------------------")
30    df['remote_work'] = df['remote_work'].map({
31        'Yes': True,
32        'No': False,
33        'Hybrid': True
34    })
35
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
dtype: int64
--------------------форматування даних у remote_work--------------------
job_title             str
experience_years    int64
education_level       str
skills_count        int64
remote_work          bool
salary              int64
company_size          str
certifications      int64
```

2.1 Загальна кількість рядків

```
# 2.1 Загальна кількість рядків
print("--------------------загальна кількість рядків--------------------")
print(len(df))      # кількість рядків
print(df.shape)     # розмірність DataFrame
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
dtype: object
--------------------загальна кількість рядків--------------------
250000
(250000, 8)
```

2.2 Робота з числовими показниками

1. Відфільтруйте записи, де певний числовий показник перевищує задане вами порогове значення (наприклад, ціна більше за 1000), та збережіть у нову змінну
2. Порахуйте скільки вийшло таких записів

```
# Відфільтровуємо записи, де skills_count > 3
print("--------------------skills_count > 3--------------------")
top_skills = df[df['skills_count'] > 3]
print(top_skills)

# Підраховуємо кількість таких записів
print("--------------------кількість записів, де skills_count > 3--------
print(len(top_skills))

# Знаходимо середнє значення salary для цієї вибірки
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
(250000, 8)
--------------------skills_count > 3--------------------
                job_title  experience_years education_level  skills_
1            Data Analyst                 5        Bachelor
2       Frontend Developer               18             PhD
3         Business Analyst               19             PhD
4          Product Manager               15        Bachelor
5              AI Engineer                0     High School
...                    ...             ...             ...
249992       Data Analyst                 7        Bachelor
249993  Frontend Developer               17             PhD
249994    Business Analyst               13         Diploma
249996  Frontend Developer               20             PhD
249997    Business Analyst                1        Bachelor

[210410 rows x 8 columns]
--------------------кількість записів, де skills_count > 3----------
210410
```

3. Знайдіть середнє значення іншого числового стовпчика для цієї відфільтрованої вибірки

```python
# Знайдіть середнє значення іншого числового стовпчика для цієї відфільтрованої ви
print("--------------------середнє знач зп з вибірки тих у кого скіли вище зазначе
print(top_skills['salary'].mean())
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
--------------------середнє знач зп з вибірки тих у кого скіли вище зазначених-
147028.32586378974

(.venv) A:\уник\4_курс\miod\miod_lab1>
```

4. Виведіть ідентифікатори 10 записів з найбільшим значенням обраного числового показника (у пункті 3 завдання 2.2)

```python
# Виводимо ідентифікатори 10 записів з найбільшим значенням salary
# Ідентифікаторами тут є стандартні індекси DataFrame
print("--------------------ідентифікатори 10 записів з найбільшим salary--------------------
top10 = df.sort_values(by='salary', ascending=False).head(10)
print(top10.index.tolist())

# За бажанням можна ще подивитися самі ці записи
print("--------------------топ 10 записів за salary--------------------")
print(top10[['job_title', 'salary']])
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
147028.32586378974
--------------------ідентифікатори 10 записів з найбільшим salary--------------------
[240392, 177309, 228928, 182335, 112992, 50683, 5971, 241267, 236878, 73065]
--------------------топ 10 записів за salary--------------------
          job_title  salary
240392  AI Engineer  333046
177309  AI Engineer  328616
228928  AI Engineer  327217
182335  AI Engineer  327025
112992  AI Engineer  325052
50683   AI Engineer  324583
50683   AI Engineer  324583
50683   AI Engineer  324583
5971    AI Engineer  324505
241267  AI Engineer  323985
236878  AI Engineer  323423
73065   AI Engineer  321127

50683   AI Engineer  324583
```

2.3 Дослідження категорій та тексту

1. Відфільтруйте дані за точним збігом у категоріальному стовпчику (наприклад, `country == 'Ukraine'`) та порахуйте кількість таких записів

```python
# 2.3 Дослідження категорій та тексту
# Відфільтруйте дані за точним збігом у категоріальному стовпчику (education_level == PhD) та порахуйте кількість таких записів
print("--------------------(education_level == PhD)--------------------")
education_filter = df[df['education_level'] == 'PhD']
print(education_filter)
print(len(education_filter))
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
2              Frontend Developer                18             PhD             4        False  148123       Medium              1
2              Frontend Developer                18             PhD             4        False  148123       Medium              1
2              Frontend Developer                18             PhD             4        False  148123       Medium              1
3                Business Analyst                19             PhD            13         True  189123       Medium              0
9              Frontend Developer                18             PhD             2         True  128377   Enterprise              5
14               Business Analyst                14             PhD             5        False  106481   Enterprise              1
16      Machine Learning Engineer                11             PhD            16         True  191757       Medium              3
...                           ...               ...             ...           ...          ...     ...          ...            ...
249982            Product Manager                1             PhD             1        False  191137        Large              3
249988                AI Engineer               15             PhD             9         True  246720   Enterprise              1
249993         Frontend Developer               17             PhD            19         True  193028   Enterprise              1
249995          Software Engineer               17             PhD             2        False  127791   Enterprise              1
249996         Frontend Developer               20             PhD             7        False  154593      Startup              2

[49857 rows x 8 columns]
49857
```

2. Відфільтруйте дані за частковим збігом (наявність підрядка) у іншому категоріальному стовпчику та запишіть у нову змінну

```python
# Відфільтруйте дані за частковим збігом (наявність підрядка) у іншому категоріальному стовпчику та запишіть у нову змінну
print("--------------------Відфільтруйте дані за частковим збігом (наявність підрядка) у іншому категоріальному стовпчику та запишіть у нову змінну----------------
job_filter = df[df['job_title'].str.startswith('AI')]
print(job_filter)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
--------------------Відфільтруйте дані за частковим збігом (наявність підрядка) у іншому категоріальному стовпчику та запишіть у нову змінну-------
-----------
          job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
0       AI Engineer                10        Bachelor             2         True  109413       Medium               2
5       AI Engineer                 0     High School             4        False  180351   Enterprise               2
8       AI Engineer                 5         Diploma            14         True  171834   Enterprise               0
40      AI Engineer                 5         Diploma            10         True  143403        Small               5
46      AI Engineer                 9          Master            10         True  194075        Large               3
...             ...               ...             ...           ...          ...    ...          ...             ...
249950  AI Engineer                19        Bachelor             6        False  150021        Large               5
249953  AI Engineer                 9          Master             4        False  164669       Medium               3
```

3. Порахуйте кількість записів, які одночасно задовольняють 1 і 2 умовам з цього блоку

```python
# Порахуйте кількість записів, які одночасно задовольняють 1 і 2 умовам з цього блоку
print("-------------------- 3. Одночасно PhD і AI --------------------")
both_filter = df[
    (df['education_level'] == 'PhD') &
    (df['job_title'].str.startswith('AI'))
]
print(both_filter)
print("Кількість записів:", len(both_filter))
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
-------------------- 3. Одночасно PhD і AI --------------------
          job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
145     AI Engineer                 6             PhD            18        False  192544        Small               4
296     AI Engineer                20             PhD            13         True  172891   Enterprise               2
342     AI Engineer                 0             PhD             7         True  139524        Small               2
379     AI Engineer                19             PhD             2         True  181589      Startup               2
450     AI Engineer                 3             PhD             5         True  114956       Medium               4
...             ...               ...             ...           ...          ...     ...          ...             ...
249912  AI Engineer                 9             PhD             1         True  225981   Enterprise               4
249931  AI Engineer                10             PhD             1        False  193577   Enterprise               3
249945  AI Engineer                 2             PhD            13        False  153302        Small               5
249973  AI Engineer                 1             PhD            11         True  161163       Medium               3
249988  AI Engineer                15             PhD             9         True  246720   Enterprise               1

[4152 rows x 8 columns]
Кількість записів: 4152
```

4. Порахуйте частку записів, які задовольніють умову 1, але не задовольняють умову 2

```python
# 4. Частка записів, які задовольняють умову 1, але не задовольняють умову 2
print("-------------------- 4. Частка: PhD, але не AI --------------------")
only_education = df[
    (df['education_level'] == 'PhD') &
    (~df['job_title'].str.startswith('AI'))
]
share_only_education = len(only_education) / len(df)
print("Кількість записів:", len(only_education))
print("Частка:", share_only_education)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
Кількість записів: 45705
Частка: 0.18282
```

5. Порахуйте кількість записів із набору даних, які не задовольняють ні 1, ні 2 умовам з цього блоку

```python
# 5. Кількість записів, які не задовольняють ні 1, ні 2 умову
print("-------------------- 5. Не PhD і не Engineer --------------------")
neither_filter = df[
    (df['education_level'] != 'PhD') &
    (~df['job_title'].str.startswith('AI'))
]
print(neither_filter)
print("Кількість записів:", len(neither_filter))
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
Частка: 0.18282
-------------------- 5. Не PhD і не Engineer --------------------
                        job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
1                    Data Analyst                 5        Bachelor            17        False   93764        Small               0
4                 Product Manager                15        Bachelor             7         True  165069        Large               0
6               Backend Developer                 6     High School            16        False  165375   Enterprise               3
7       Machine Learning Engineer                 4        Bachelor            18         True  202463   Enterprise               5
10             Frontend Developer                 1     High School            10         True  105755        Large               5
...                           ...               ...             ...           ...          ...     ...          ...             ...
249992               Data Analyst                 7        Bachelor             4        False   94870        Large               0
249994           Business Analyst                13         Diploma            17         True  171896        Large               3
249997           Business Analyst                 1        Bachelor            12         True   75988   Enterprise               0
249998             Data Scientist                 0     High School             2         True   90467        Small               5
249999               Data Analyst                16         Diploma             2        False  133084       Medium               5

[183350 rows x 8 columns]
[183350 rows x 8 columns]
[183350 rows x 8 columns]
Кількість записів: 183350
```

2.4 Дослідження числових діапазонів та зрізів даних

1. Оберіть один числовий або категоріальний стовпчик. Порахуйте кількість записів, які дорівнюють одному конкретному значенню (наприклад, конкретний вік `age == 25`)

```python
# Оберіть один числовий або категоріальний стовпчик. Порахуйте кількість записів, які дорівнюють одному конкретному значенню (наприклад, конкретний вік age == 25)
print("-------------------- experience=7 --------------------")
experience_7 = df[df['experience_years'] == 7]
print(experience_7)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
-------------------- experience=7 --------------------
                job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
28        Backend Developer                 7         Diploma            15        False  119988       Medium               3
154          Data Scientist                 7          Master             6         True  126020        Small               2
165         DevOps Engineer                 7             PhD            16         True  154734       Medium               0
180   Cybersecurity Analyst                 7     High School            12        False  131691       Medium               1
180   Cybersecurity Analyst                 7     High School            12        False  131691       Medium               1
180   Cybersecurity Analyst                 7     High School            12        False  131691       Medium               1
180   Cybersecurity Analyst                 7     High School            12        False  131691       Medium               1
180   Cybersecurity Analyst                 7     High School            12        False  131691       Medium               1
199       Backend Developer                 7     High School             5         True  114572       Medium               2
...                     ...               ...             ...           ...          ...     ...          ...             ...
249937    Software Engineer                 7             PhD            16         True  154925       Medium               3
249938      Product Manager                 7     High School             7         True  118287       Medium               0
249956        Data Scientist                7         Diploma            16         True  122021       Medium               1
249975     Business Analyst                 7        Bachelor            15         True  117653      Startup               3
249992         Data Analyst                 7        Bachelor             4        False   94870        Large               0

[11981 rows x 8 columns]
```

2. Оберіть числовий стовпчик. Порахуйте кількість записів, значення яких потрапляють у певний діапазон (наприклад, вік від 17 до 20). Спробуйте зробити це за допомогою однієї комплексної умови бех створення зайвих змінних

```python
# діапазон значень у стовпчику
print("-------------------- experience=7-10 --------------------")
print(len(df[(df['experience_years'] >= 7) & (df['experience_years'] <= 10)]))
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
[11981 rows x 8 columns]
-------------------- experience=7-10 --------------------
47436
```

3. Напишіть логічну перевірку, щоб дізнатись, чи була кількість записів у підмножині з першої умови цього блоку більшою, ніж у підмножині з другої умови цього блоку.

```python
# кого більше з досвідом 7 років чи 7-10
experience_7_10 = df[(7 >= df['experience_years']) & (df['experience_years'] <= 10)]
print("-------------------- кого більше з досвідом 7 років чи 10 --------------------")
print(len(experience_7) > len(experience_7_10))
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
47436
-------------------- кого більше з досвідом 7 років чи 10 --------------------
False
```

2.5 Комбіновані фільтри та оцінки

1. Відфільтруйте записи, які є “значущими” (наприклад, мають більше 100 відгуків, або кількість продажів > 500
2. Виведіть топ-5 записів з найвищим показником з цієї нової вибірки
3. Порахуйте медіану або середнє значення для топ-10 записів, відсортованих за іншим показником

```python
# 2.5 Комбіновані фільтри та оцінки
print("-------------------- зп більша 250к --------------------")
best_salary = df[df['salary'] > 250000]
print(best_salary)

print("-------------------- зп більша 250к і найбільший експіріенс ------------------
print(best_salary.sort_values('experience_years', ascending=False).head())
# best_salary.nlargest(5, 'experience_years') - альтернатива

print("-------------------- середнє та медіана experience_years для топ-10 за salary
# top10 - це ідентифікатори 10 записів з найбільшим salary
print("Середнє experience_years:", top10['experience_years'].mean())
print("Медіана experience_years:", top10['experience_years'].median())
```

```
-------------------- зп більша 250к --------------------
                      job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
159                  AI Engineer                 6          Master            18         True  257220   Enterprise               2
536     Machine Learning Engineer                18             PhD             4        False  271175   Enterprise               4
628                  AI Engineer                18         Diploma            14         True  260034        Large               2
638                  AI Engineer                17         Diploma            10         True  268299   Enterprise               5
790               DevOps Engineer               20             PhD             7         True  253445   Enterprise               4
...                           ...              ...             ...           ...          ...     ...          ...             ...
249521  Machine Learning Engineer                16          Master            11        False  252737   Enterprise               4
249678               AI Engineer                 9          Master            15         True  255650   Enterprise               4
249704          Software Engineer               16          Master             8         True  257779   Enterprise               5
249847             Cloud Engineer               20          Master            14        False  262368   Enterprise               0
249911               AI Engineer                17        Bachelor            16        False  251486        Large               2

[1710 rows x 8 columns]
-------------------- зп більша 250к і найбільший експіріенс --------------------
                      job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
951                Cloud Engineer               20             PhD            16        False  292855   Enterprise               4
249847             Cloud Engineer               20          Master            14        False  262368   Enterprise               0
1997                 AI Engineer                20        Bachelor            13         True  255356       Medium               3
2705                 AI Engineer                20         Diploma            16         True  257693   Enterprise               0
2992    Machine Learning Engineer               20        Bachelor            11        False  250619        Large               4
-------------------- середнє та медіана experience_years для топ-10 за salary --------------------
Середнє experience_years: 18.5
Медіана experience_years: 18.5
```

2.6 Порівняння груп

1. Оберіть дві різні категорії (наприклад, два різних бренди, дві країни, дві компанії). Створіть два окремих `DataFrame`, кожен з котрих буде містити виключно одну із обраних категорій

```python
# Створіть два окремих DataFrame, кожен з котрих буде містити виключно одну із обраних категорій
print("-------------------- створили 2 нових датасета з job_title: df_ai_engin і df_cloud_engin--------------------")
df_ai_engin = df[df['job_title'] == 'AI Engineer']
print(df_ai_engin)
df_cloud_engin = df[df['job_title'] == 'Cloud Engineer']
print(df_cloud_engin)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
-------------------- створили 2 нових датасета з job_title --------------------
          job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
0       AI Engineer                10        Bachelor             2         True  109413      Medium               2
5       AI Engineer                 0     High School             4        False  180351  Enterprise               2
8       AI Engineer                 5         Diploma            14         True  171834  Enterprise               0
40      AI Engineer                 5         Diploma            10         True  143403       Small               5
46      AI Engineer                 9          Master            10         True  194075       Large               3
...             ...               ...             ...           ...          ...     ...         ...             ...
249950  AI Engineer                19        Bachelor             6        False  150021       Large               5
249953  AI Engineer                 9          Master             4        False  164669      Medium               3
249954  AI Engineer                12     High School            14         True  156565      Medium               5
249973  AI Engineer                 1             PhD            11         True  161163      Medium               3
249988  AI Engineer                15             PhD             9         True  246720  Enterprise               1

[20945 rows x 8 columns]
             job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
31      Cloud Engineer                 8             PhD             3        False  162923      Medium               0
42      Cloud Engineer                 5             PhD             4         True  152413       Small               4
48      Cloud Engineer                14         Diploma            14        False  155886      Medium               4
```

2. Створіть новий `DataFrame`, який базується на цих двох змінних. Він повинен мати стовпчик `category_name` із назвою категорії, та стовпчик `total_records` з підрахованою кількістю записів для кожної групи
3. Додайте до створеного `DataFrame` новий стовпчик `average_value`, де порахуйте середнє значення певного числового показника для кожної з двох груп

```python
# Створіть новий DataFrame, який базується на цих двох змінних. Він повинен мати стовпчик cat
print("-------------------- новий DataFrame, на AI Engineer', 'Cloud Engineer. category_name
summary_data = pd.DataFrame({
    'category_name': ['AI Engineer', 'Cloud Engineer'],
    'total_records': [len(df_ai_engin), len(df_cloud_engin)]
})
print(summary_data)

print("-------------------- додали average_experiance, де середнє значення experience_years -
# зробили змінні з середніми значеннями в категорії
avg_ai = df_ai_engin['experience_years'].mean()
avg_cloud = df_cloud_engin['experience_years'].mean()

# додали average_experiance
summary_data['average_experiance'] = [avg_ai, avg_cloud]
print(summary_data)
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
-------------------- новий DataFrame, на AI Engineer', 'Cloud Engineer. category_name
ть записів для кожної групи--------------------
    category_name  total_records
0     AI Engineer          20945
1  Cloud Engineer          20686
-------------------- додали average_experiance, де середнє значення experience_years -
    category_name  total_records  average_experiance
0     AI Engineer          20945            9.997422
1  Cloud Engineer          20686           10.023591
```

2.7 Комплексні завдання

1. Напишіть складний фільтр для набору даних, який використовує одночасно оператори `AND`, `OR`, `NOT`

```python
# 2.6 Складний фільтр з AND, OR, NOT
print("------------------- складний фільтр: salary > 200000  + education_level == 'PhD' + remote_work == True + не Small комп-------------------")
complex_filter = df[
    (df['salary'] > 200000) &
    (
        (df['education_level'] == 'PhD') |
        (df['remote_work'] == True)
    ) &
    ~(df['company_size'] == 'Small')
]
# Виводимо всі записи, які задовольняють складний фільтр
print(complex_filter)
# Виводимо кількість знайдених записів
print("Кількість записів за складним фільтром:", len(complex_filter))
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
------------------- складний фільтр: salary > 200000  + education_level == 'PhD' + remote_work == True + не Small комп-------------------
                     job_title  experience_years education_level  skills_count  remote_work  salary company_size  certifications
7       Machine Learning Engineer                 4        Bachelor            18         True  202463   Enterprise               5
38      Machine Learning Engineer                15             PhD            15         True  213920       Medium               5
43      Machine Learning Engineer                15     High School            15         True  212249   Enterprise               2
69              Software Engineer                 6          Master            16         True  200988        Large               4
73                DevOps Engineer                 9             PhD             4         True  208215   Enterprise               1
...                           ...               ...             ...           ...          ...     ...          ...             ...
249890         Frontend Developer                19             PhD             2         True  200310        Large               2
249912                AI Engineer                 9             PhD             1         True  225981   Enterprise               4
249921      Cybersecurity Analyst                 8          Master             8         True  207942   Enterprise               5
249971            Product Manager                15             PhD            13         True  212857       Medium               3
249988                AI Engineer                15             PhD             9         True  246720   Enterprise               1

[15784 rows x 8 columns]
Кількість записів за складним фільтром: 15784
```

2. За допомогою методу `.plot()` з бібліотеки `matplotlib` побудуйте графік, який візуалізує певну закономірність, тренд або розподіл у вашому наборі даних. Оберіть тип графіка (лінійний, стовпчастий, гістограма, тощо), який найкраще розкриває суть обраних вами даних.

```python
print(complex_filter)
print("Кількість записів за складним фільтром:", len(complex_filter))

print("------------------- графік salary від experience -------------
df.plot(x='experience_years', y='salary', kind='scatter', alpha=0.3)
plt.show()
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ
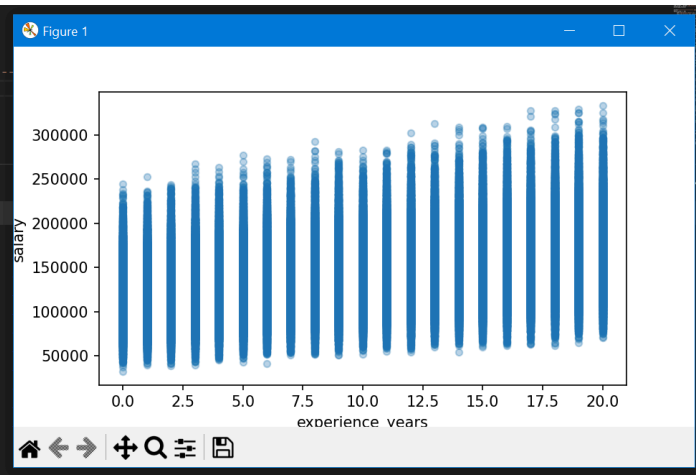
```
7       Machine Learning Engineer                 4        Bachelor
38      Machine Learning Engineer                15             PhD
43      Machine Learning Engineer                15     High School
69              Software Engineer                 6          Master
73                DevOps Engineer                 9             PhD
...                           ...               ...             ...
249890         Frontend Developer                19             PhD
249912                AI Engineer                 9             PhD
249921      Cybersecurity Analyst                 8          Master
249971            Product Manager                15             PhD
249988                AI Engineer                15             PhD

[15784 rows x 8 columns]
Кількість записів за складним фільтром: 15784
------------------- графік salary від experience -------------------
```