ЗВІТ БЕЗКРОВНА МІОД ЛАБ2

Встановлення бібліотек у венв:

python -m pip install pandas numpy matplotlib

Запуск проекту:

python miod_lab2.py

ЗАВДАННЯ 1. ПІДГОТОВКА НАБОРУ ДАНИХ

1.1 Вибір та завантаження набору даних

```python
# 1.1
df = pd.read_csv('job_dataset.csv') # Завантажуємо набір даних у DataFrame без зміни стандартного індексу
print(df.head())
```

ПРОБЛЕМЫ ВЫХОДНЫЕ ДАННЫЕ ПОРТЫ AZURE

ТЕРМИНАЛ

```
(.venv) A:\уник\4_курс\miod\miod_lab2>python miod_lab2.py
           job_title  experience_years education_level  skills_count  ...   location remote_work certifications  salary
0         AI Engineer                10        Bachelor             2  ...      India      Hybrid              2  109413
1        Data Analyst                 5        Bachelor            17  ...  Australia          No              0   93764
2  Frontend Developer                18             PhD             4  ...  Singapore          No              1  148123
3    Business Analyst                19             PhD            13  ...     Canada         Yes              0  189123
4     Product Manager                15        Bachelor             7  ...     Sweden         Yes              0  165069

[5 rows x 10 columns]
```

1.2 Базова підготовка даних

Обробка пропусків. Зміна типів даних. Фільтрація аномалій.

```
(.venv) A:\уник\4_курс\miod\miod_lab2>python miod_lab2.py
------------------- Перші 5 рядків -------------------
           job_title  experience_years education_level  skills_count       industry company_size   location remote_work  certifications  salary
0         AI Engineer                10        Bachelor             2     Healthcare       Medium      India      Hybrid               2  109413
1        Data Analyst                 5        Bachelor            17        Telecom        Small  Australia          No               0   93764
2  Frontend Developer                18             PhD             4          Media       Medium  Singapore          No               1  148123
3    Business Analyst                19             PhD            13         Retail       Medium     Canada         Yes               0  189123
4     Product Manager                15        Bachelor             7  Manufacturing        Large     Sweden         Yes               0  165069
------------------- Перевірка пропусків -------------------
job_title           0
experience_years    0
education_level     0
skills_count        0
industry            0
company_size        0
location            0
remote_work         0
certifications      0
salary              0
dtype: int64
------------------- Типи даних до змін -------------------
job_title             str
experience_years    int64
education_level       str
skills_count        int64
industry              str
company_size          str
location              str
```

```
company_size          str
location              str
remote_work           str
certifications      int64
salary              int64
dtype: object
------------------- Форматування даних у remote_work -------------------
job_title             str
experience_years    int64
education_level       str
skills_count        int64
industry              str
company_size          str
location              str
remote_work          bool
certifications      int64
salary              int64
dtype: object
------------------- Дані після зміни remote_work -------------------
                job_title  experience_years education_level  skills_count       industry company_size   location  remote_work  certifications  salary
0             AI Engineer                10        Bachelor             2     Healthcare       Medium      India         True               2  109413
1            Data Analyst                 5        Bachelor            17        Telecom        Small  Australia        False               0   93764
2       Frontend Developer                18             PhD             4          Media       Medium  Singapore        False               1  148123
3         Business Analyst                19             PhD            13         Retail       Medium     Canada         True               0  189123
4          Product Manager                15        Bachelor             7  Manufacturing        Large     Sweden         True               0  165069
2       Frontend Developer                18             PhD             4          Media       Medium  Singapore        False               1  148123
3         Business Analyst                19             PhD            13         Retail       Medium     Canada         True               0  189123
4          Product Manager                15        Bachelor             7  Manufacturing        Large     Sweden         True               0  165069
```

ЗАВДАННЯ 2. ВІЗУАЛЬНИЙ АНАЛІЗ ДАНИХ

2.1 Розподіл однієї змінної

```
# ЗАВДАННЯ 2. ВІЗУАЛЬНИЙ АНАЛІЗ ДАНИХ
print("-------------------- Розподіл salary з розбиттям за посадами job_title --------------------")

plt.figure(figsize=(10, 6)) # Задаємо розмір вікна графіка

sns.histplot(
    data=df_plot,
    x='salary',
    hue='job_title',
    kde=True,
    bins=25
)

# Додаємо вертикальну лінію середнього значення зарплати
plt.axvline(
    df_plot['salary'].mean(),
    color='red',
    linestyle='--',
    label=f"Mean: {df_plot['salary'].mean():.1f}"
)

plt.title('Розподіл зарплатні для 5 найпоширеніших посад')
plt.xlabel('Зарплатня')
plt.ylabel('Кількість записів у данному діапазоні')
plt.legend()
plt.show()
```

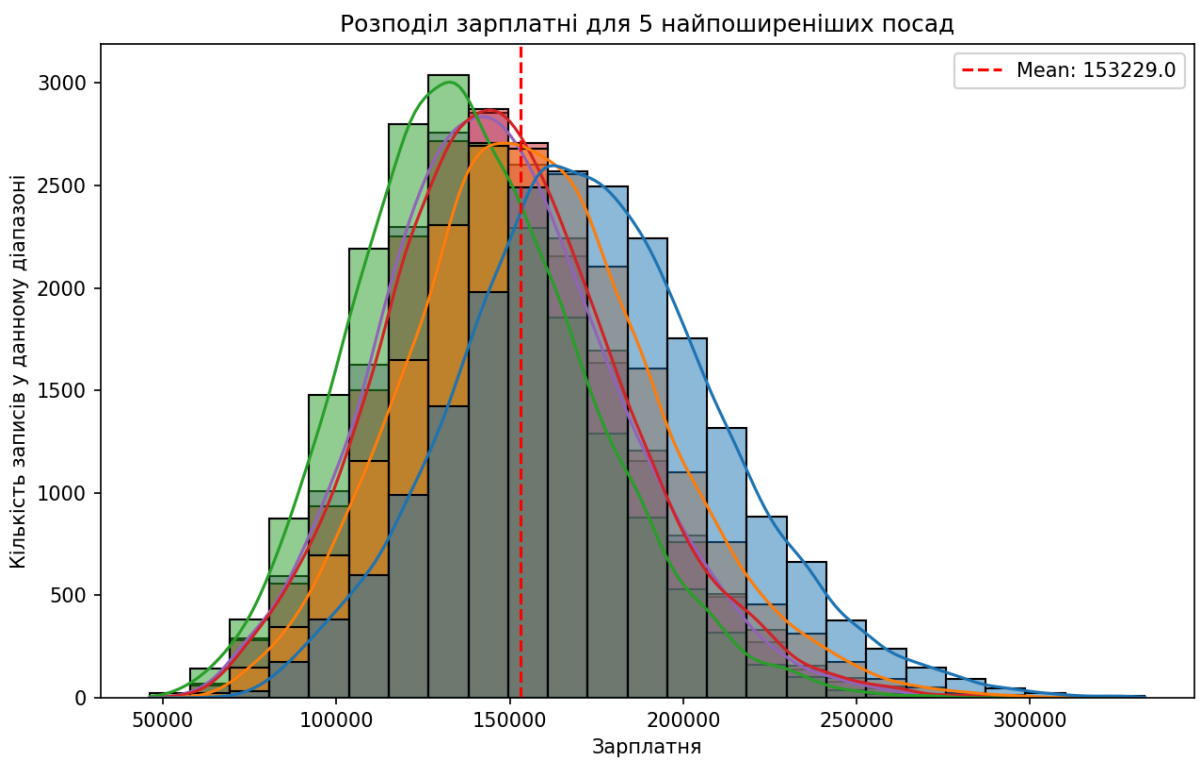

2.2 Порівняння категорій

Було побудовано стовпчикову діаграму, яка показує середню зарплату для різних посад. Додатково використано параметр hue для розбиття за типом роботи (віддалена/офіс).

```
print("-------------------- Середня зарплата по посадах з розбиттям за remote_work --------------------")
# Групування даних: обчислюємо середнє значення заробітної плати (salary) для кожної комбінації посади (job_title) та типу роботи (remote_work)
avg_salary = df_plot.groupby(['job_title', 'remote_work'])['salary'].mean().reset_index()
plt.figure(figsize=(12, 6)) # Створення області для побудови графіка
palette = {False: 'blue', True: 'orange'} # кольори для категорій

# Побудова стовпчикової діаграми:
sns.barplot(
    data=avg_salary,
    x='job_title',
    y='salary',
    hue='remote_work', # hue — додатковий вимір (тип роботи)
    palette=palette # щоб відображались саме мої кольори
)
plt.title('Середня зарплата по посадах з розбиттям за типом роботи')
plt.xlabel('Посада')
plt.ylabel('Середня зарплата')
plt.xticks(rotation=20) # Поворот підписів осі X

# Налаштування легенди:
handles, _ = plt.gca().get_legend_handles_labels() # отримуємо поточні графічні елементи (handles)
plt.legend(
    handles=handles,
    labels=['False (офіс)', 'True (віддалено/гібрид)'],
    title='Віддалена робота'
)

# Додавання сітки для кращого візуального сприйняття
plt.grid(
    axis='y',
    linestyle='--',
    alpha=0.5
)
plt.grid(...
plt.show()
```

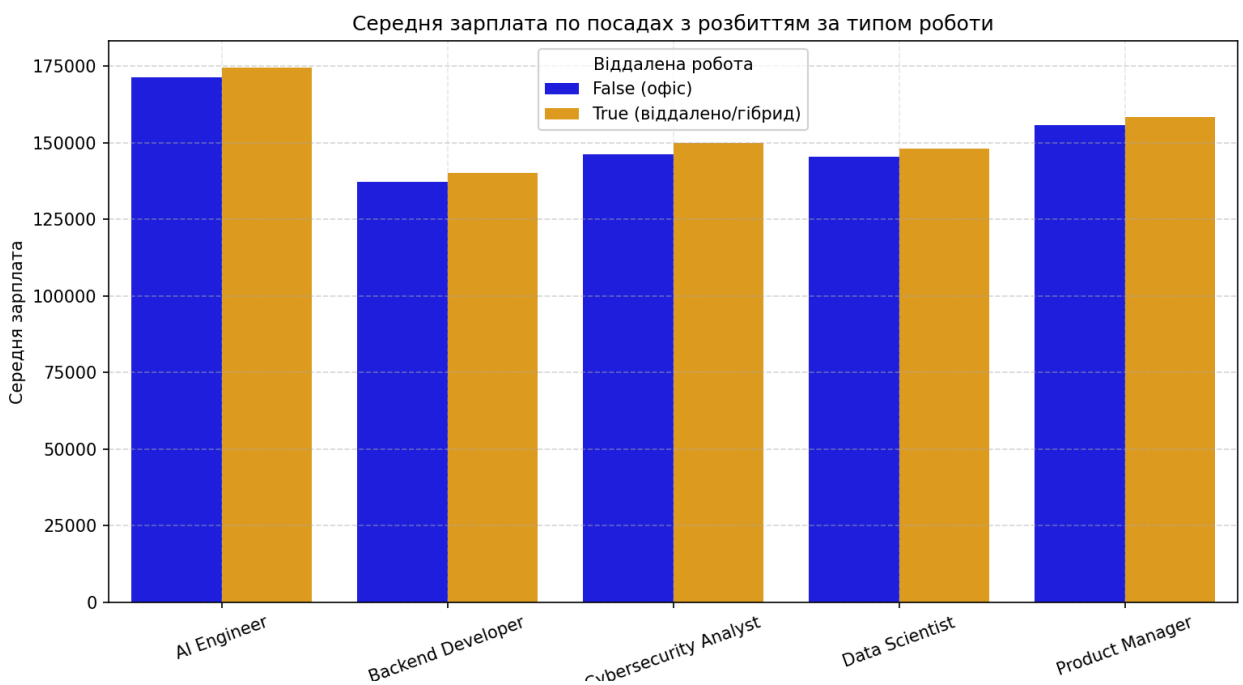

2.3 Аналіз розкиду та викидів

```
print("-------------------- Аналіз розкиду та викидів. Розподіл зарплати за посадами -
plt.figure(figsize=(12, 6))

# Будуємо boxplot
sns.boxplot(
    data=df_plot,
    x='job_title',
    y='salary',
    palette='pastel'
)

# Заголовок і підписи осей
plt.title('Розподіл зарплати за посадами')
plt.xlabel('Посада')
plt.ylabel('Зарплата')

plt.xticks(rotation=20)

# Додаємо горизонтальні лінії сітки для зручнішого читання значень
plt.grid(...
plt.show()
```

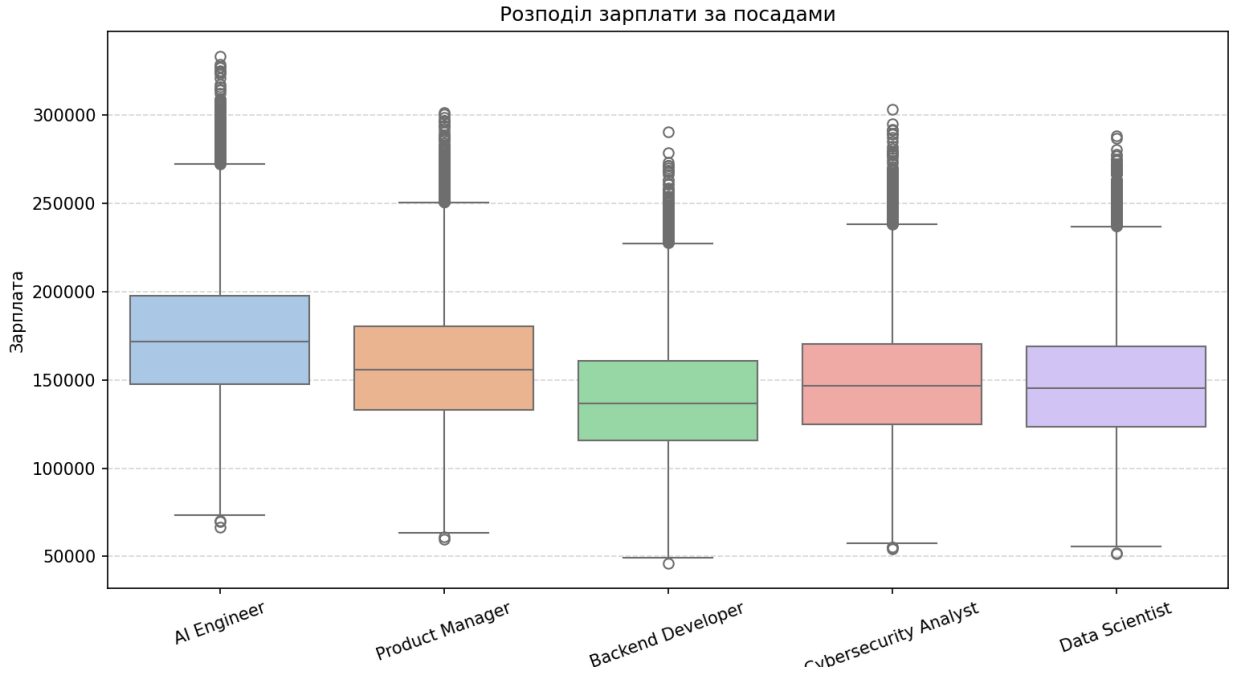

2.4 Структура та пропорції

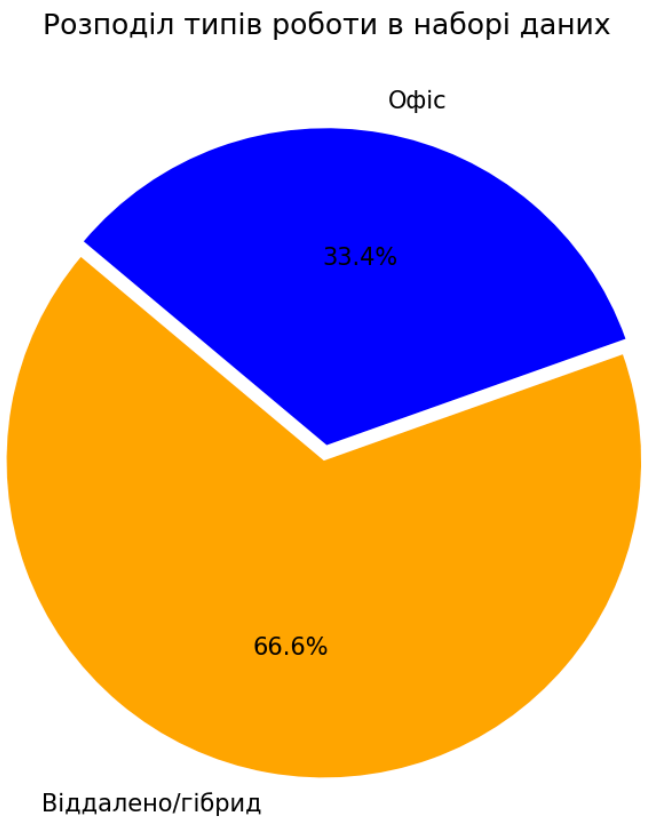


```python
print("-------------------- 2.4 Частка типів роботи --------------------")

# Рахуємо кількість кожної категорії
remote_counts = df['remote_work'].value_counts()

# Перетворюємо True/False у зрозумілий текст
labels = ['Віддалено/гібрид' if x else 'Офіс' for x in remote_counts.index]

plt.figure(figsize=(6, 6))

# Побудова кругової діаграми
plt.pie(
    remote_counts,
    labels=labels,
    autopct='%1.1f%%',   # показує відсотки
    startangle=140,      # поворот діаграми
    colors=['orange', 'blue'],  # кольори як у попередньому графіку
    explode=(0.05, 0)    # трохи "висуваємо" один сектор
)

plt.title('Розподіл типів роботи в наборі даних')

plt.show()
```

2.5 Взаємозв'язок двох числових змінних

```
print("-------------------- 2.5 Залежність зарплати від досвіду та освіти ---

plt.figure(figsize=(10, 6))

# Побудова точкової діаграми:
sns.scatterplot(
    data=df_plot,
    x='experience_years',
    y='salary',
    hue='education_level',
    alpha=0.5  # прозорість точок
)

# Додавання лінії тренду: показує загальну тенденцію залежності між змінними
sns.regplot(
    data=df_plot,
    x='experience_years',
    y='salary',
    scatter=False,      # не малюємо точки повторно
    color='red',        # колір лінії тренду
    line_kws={'linewidth': 2}
)

# Оформлення графіка
plt.xlabel('Досвід роботи (роки)')
plt.ylabel('Зарплата')
plt.title('Залежність зарплати від досвіду та рівня освіти')
plt.legend(title='Рівень освіти')
# Додаємо сітку для кращого читання значень
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```

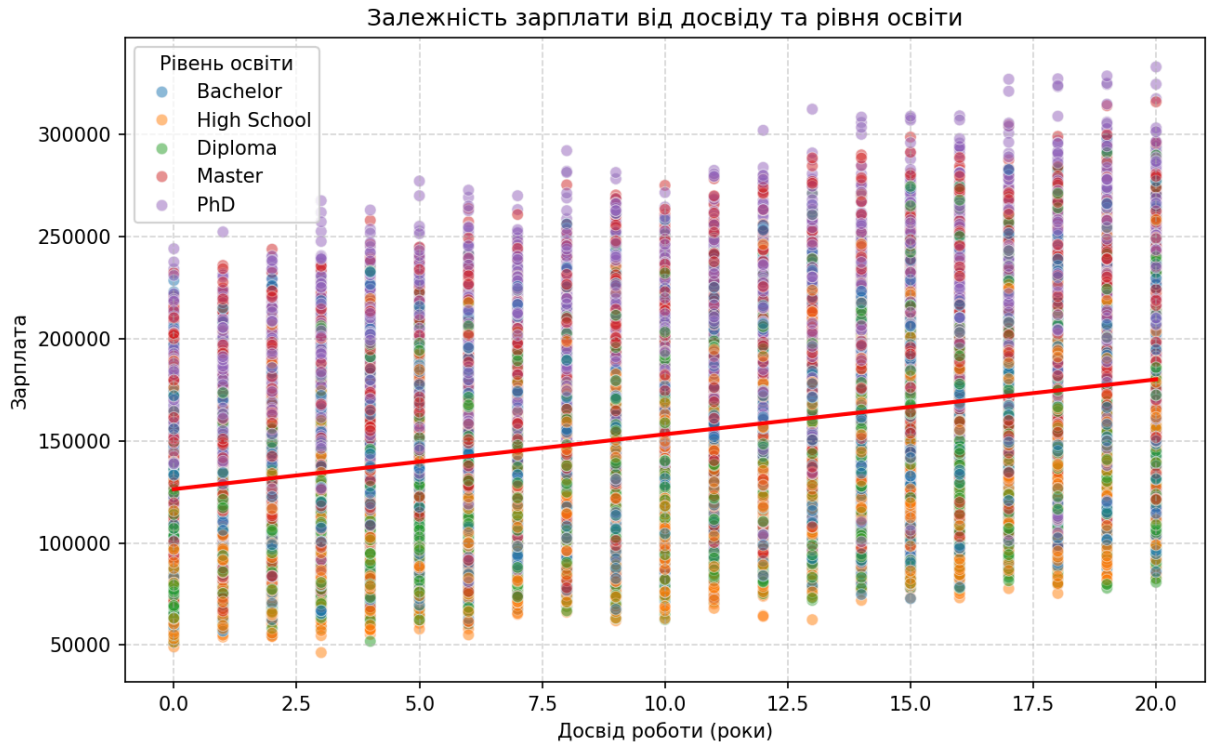

2.6 Динаміка або тренд

```python
print("-------------------- 2.6 Динаміка або тренд. Зміна середньої зарплати залежно від рівня освіти

# Задаємо логічний порядок рівнів освіти
education_order = ['High School', 'Diploma', 'Bachelor', 'Master', 'PhD']

# Групуємо дані за education_level і рахуємо середню зарплату
trend_data = df.groupby('education_level')['salary'].mean().reindex(education_order)

# Побудова лінійного графіка
plt.figure(figsize=(10, 6))

plt.plot(
    trend_data.index,     # вісь X — рівні освіти у заданому порядку
    trend_data.values,    # вісь Y — середня зарплата
    marker='o',           # позначки на точках
    linestyle='-',        # тип лінії
    linewidth=2,          # товщина лінії
    color='darkblue'      # колір лінії
)

# Оформлення графіка
plt.title('Зміна середньої зарплати залежно від рівня освіти')
plt.xlabel('Рівень освіти')
plt.ylabel('Середня зарплата')

# Додаємо сітку
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```

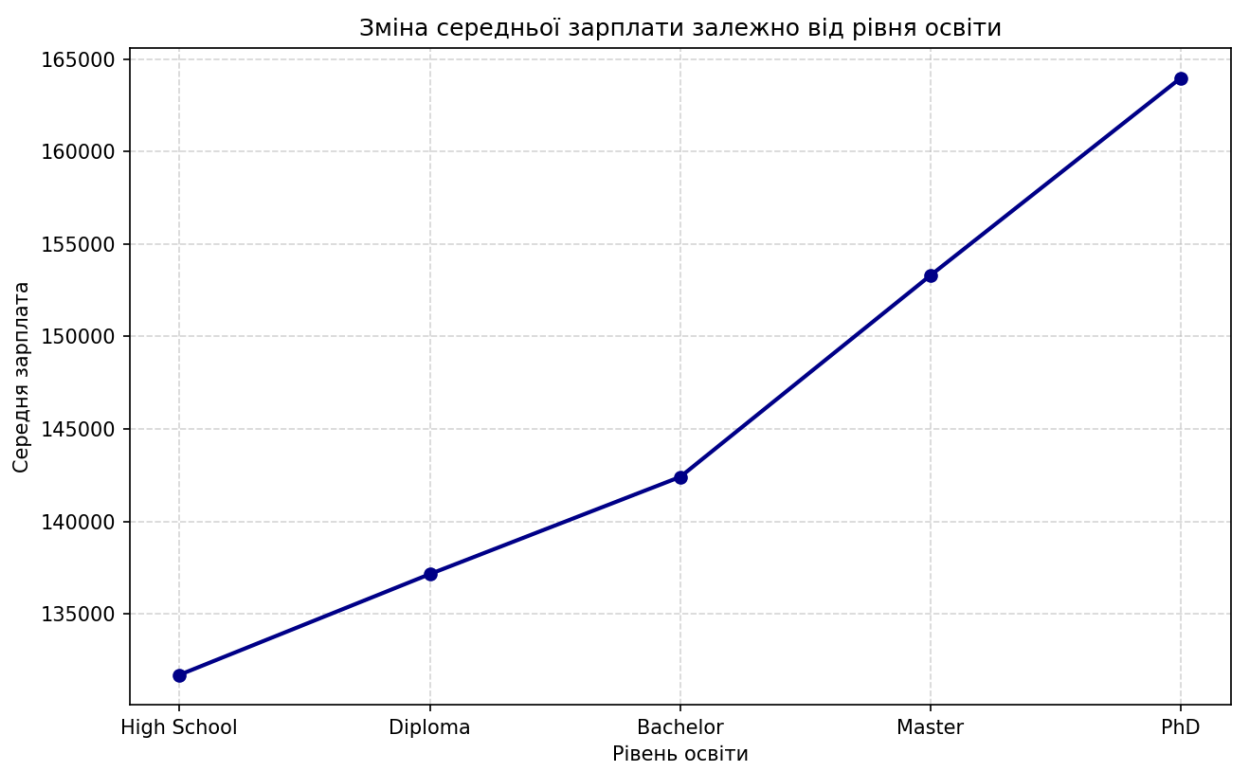

2.7 Матриця кореляцій

Найбільша залежність спостерігається між досвідом роботи та рівнем заробітної плати (0.44), що свідчить про те, що зі зростанням досвіду збільшується і зарплата.
Інші змінні, такі як кількість навичок та сертифікатів, мають слабкий або майже відсутній вплив на рівень зарплати.

```python
print("-------------------- Матриця кореляцій --------------------")

# Обираємо тільки числові колонки
numeric_cols = df[['experience_years', 'skills_count', 'salary', 'certifications']]

# Рахуємо матрицю кореляцій
corr_matrix = numeric_cols.corr()

plt.figure(figsize=(8, 6))

# Будуємо теплову карту
sns.heatmap(
    corr_matrix,
    annot=True,        # показує числа всередині клітинок
    cmap='coolwarm',   # кольорова схема (синій → червоний)
    fmt='.2f',         # формат чисел (2 знаки після коми)
    linewidths=0.5     # тонкі лінії між клітинками
)

plt.title('Матриця кореляцій числових змінних')
plt.show()
```

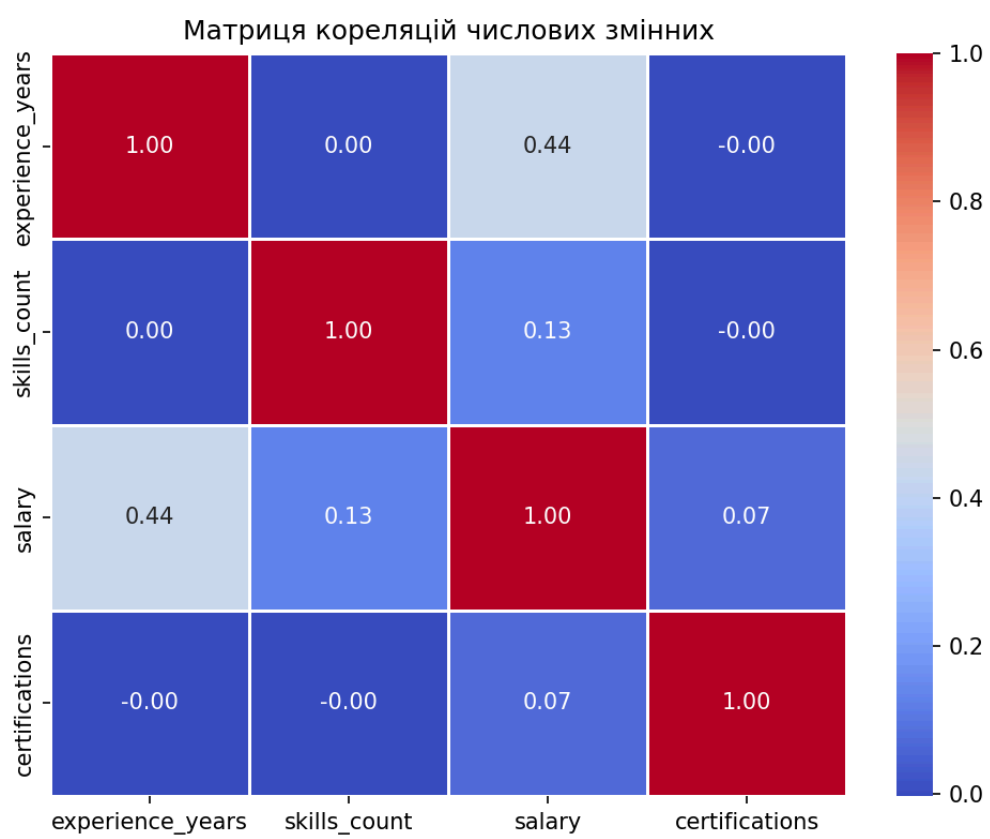

2.8 Комбінований графік

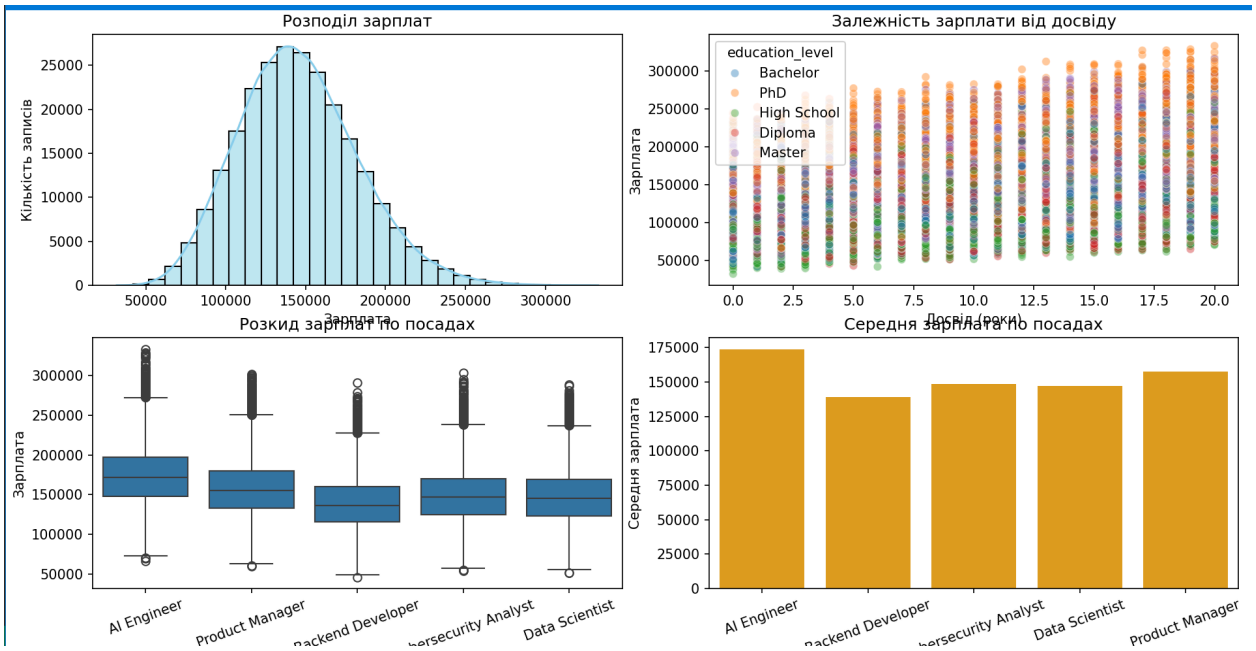


```
print("-------------------- 2.8 Комбінований графік --------------------")

# Крок 1. Створюємо полотно для 4 графіків
fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# Крок 2. Побудова гістограми розподілу зарплат - відображає, як розподілені значення
salary у наборі даних
sns.histplot(
    data=df,
    x='salary',
    bins=30,           # кількість інтервалів
    kde=True,          # додає криву щільності розподілу
    color='skyblue',
    ax=axes[0, 0]      # розміщення графіка (рядок 0, колонка 0)
)
axes[0, 0].set_title('Розподіл зарплат')
axes[0, 0].set_xlabel('Зарплата')
axes[0, 0].set_ylabel('Кількість записів')

# Крок 3. Побудова точкового графіка (scatter plot) - показує залежність зарплати від
досвіду роботи
sns.scatterplot(
    data=df,
    x='experience_years',
    y='salary',
    hue='education_level',  # розбиття за категорією
```

```
    alpha=0.4,              # прозорість точок
    ax=axes[0, 1]
)
axes[0, 1].set_title('Залежність зарплати від досвіду')
axes[0, 1].set_xlabel('Досвід (роки)')
axes[0, 1].set_ylabel('Зарплата')

# Крок 4. Відбір даних для топ-5 найпоширеніших посад повтор)
top_jobs = df['job_title'].value_counts().head(5).index
df_plot = df[df['job_title'].isin(top_jobs)]

# Крок 5. Побудова boxplot (ящик з вусами)
# Відображає розкид значень зарплати для кожної посади
sns.boxplot(
    data=df_plot,
    x='job_title',
    y='salary',
    ax=axes[1, 0]
)
axes[1, 0].set_title('Розкид зарплат по посадах')
axes[1, 0].set_xlabel('Посада')
axes[1, 0].set_ylabel('Зарплата')
# Повертаємо підписи для зручності читання
axes[1, 0].tick_params(axis='x', rotation=20)

# Крок 6. Групування даних для обчислення середньої зарплати - для кожної посади
рахуємо середнє значення salary
avg_salary = df_plot.groupby('job_title')['salary'].mean().reset_index()

# Крок 7. Побудова стовпчикової діаграми - показує середню зарплату для кожної посади
sns.barplot(
    data=avg_salary,
    x='job_title',
    y='salary',
    color='orange',
    ax=axes[1, 1]
)
axes[1, 1].set_title('Середня зарплата по посадах')
axes[1, 1].set_xlabel('Посада')
axes[1, 1].set_ylabel('Середня зарплата')
axes[1, 1].tick_params(axis='x', rotation=20)

# Крок 8. Автоматичне вирівнювання графіків
plt.tight_layout()
plt.show()
```