ЗВІТ БЕЗКРОВНА МІОД ЛАБ3 “Лінійна регресія та попередня обробка даних”
Встановлення бібліотек у венв:
python -m pip install pandas numpy matplotlib seaborn scikit-learn jinja2
Запуск проекту: python miod_lab3.py
ttps://www.kaggle.com/datasets/ssssws/chocolate-sales-dataset-2023-2024

ЗАВДАННЯ 1. ПІДГОТОВКА НАБОРУ ДАНИХ

1.1 Вибір та завантаження набору даних

Використовуючи бібліотеку pandas завантажте набір даних у DataFrame та виведіть перші 5 рядків для перевірки

```
-------------------- 1.1 Перші 5 рядків --------------------
      order_id  order_date product_id store_id customer_id  quantity  unit_price  discount  revenue   cost  profit
0  0RD00000001  2023-01-07      P0080     S093     C040749         5       14.43      0.15    61.33  42.77   18.56
1  0RD00000002  2023-10-22      P0173     S065     C020161         3       12.01      0.00    36.03  19.06   16.97
2  0RD00000003  2023-05-07      P0115     S078     C048069         2       10.02      0.00    20.04  10.29    9.75
3  0RD00000004  2024-06-23      P0186     S088     C047901         2       14.66      0.10    26.39  16.35   10.04
4  0RD00000005  2024-09-24      P0197     S054     C033950         1       12.34      0.00    12.34   7.94    4.40
Розмір датасету:
(1000000, 11)

-------------------- Типи даних у початковому наборі --------------------
order_id           str
order_date         str
product_id         str
store_id           str
customer_id        str
quantity         int64
unit_price     float64
discount       float64
revenue        float64
cost           float64
profit         float64
```

1.2 Базова підготовка даних

Зміна типів даних та вибір колонок. Переконайтеся, що всі стовпчики мають коректний тип даних, який відповідає їхньому логічному змісту. Виберіть від 5 до 10 числових колонок, які будуть ознаками і одну числову колонку, яка буде цільовою змінною.

```
-------------------- Форматування order_date --------------------
order_id                  str
order_date     datetime64[us]
product_id                str
store_id                  str
customer_id               str
quantity                int64
unit_price            float64
discount              float64
revenue               float64
cost                  float64
profit                float64
dtype: object

-------------------- Вибір числових колонок --------------------
   quantity  unit_price  discount  revenue   cost  profit
0         5       14.43      0.15    61.33  42.77   18.56
1         3       12.01      0.00    36.03  19.06   16.97
2         2       10.02      0.00    20.04  10.29    9.75
3         2       14.66      0.10    26.39  16.35   10.04
4         1       12.34      0.00    12.34   7.94    4.40
```

Обробка пропусків. Перевірте дані на наявність пропущених значень та видаліть ці рядки або заповніть їх, де треба (наприклад медіаною).

```
------------------- Перевірка пропущених значень -------------------
quantity      0
unit_price    0
discount      0
revenue       0
cost          0
profit        0
dtype: int64

------------------- Пропуски після обробки -------------------
quantity      0
unit_price    0
discount      0
revenue       0
cost          0
profit        0
dtype: int64
```

Фільтрація аномалій. Оскільки регресійні моделі залежні від аномалій, то видаліть з кожної з вибраних у кроці 2 колонок аномальні значення будь-яким способом.

```
-------------------- Фільтрація аномалій --------------------
(970405, 6)
   quantity  unit_price  discount  revenue   cost  profit
1         3       12.01       0.0    36.03  19.06   16.97
2         2       10.02       0.0    20.04  10.29    9.75
3         2       14.66       0.1    26.39  16.35   10.04
4         1       12.34       0.0    12.34   7.94    4.40
5         4       13.52       0.0    54.08  36.59   17.49
```

1.3 Знаходження залежностей

1.3.1 Обчисліть кореляційну матрицю для набору даних. Показує наскільки сильно пов'язані між собою змінні. `revenue`, `cost`, `profit` — дуже сильно пов'язані між собою

```
-------------------- Кореляційна матриця --------------------
            quantity  unit_price  discount   revenue      cost    profit
quantity    1.000000   -0.061640  0.023822  0.721968  0.709499  0.698644
unit_price -0.061640    1.000000  0.022739  0.565813  0.556808  0.546385
discount    0.023822    0.022739  1.000000 -0.093271 -0.091866 -0.089949
revenue     0.721968    0.565813 -0.093271  1.000000  0.984550  0.964967
cost        0.709499    0.556808 -0.091866  0.984550  1.000000  0.904117
profit      0.698644    0.546385 -0.089949  0.964967  0.904117  1.000000
```

1.3.2 Візуалізуйте матрицю кореляцій як теплову карту (попередня робота). Виведіть ознаки у порядку сили зв'язку із цільовою змінною.

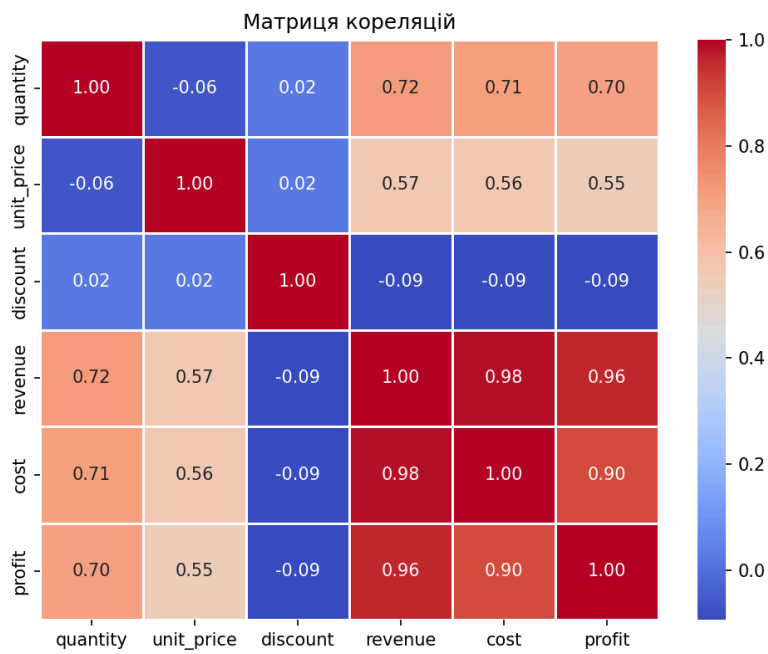


```
------------------- Сила зв'язку ознак з profit -------------------
revenue       0.964967
cost          0.904117
quantity      0.698644
unit_price    0.546385
discount     -0.089949
Name: profit, dtype: float64

Поріг сильної кореляції: 0.85
```

1.3.3 З пар ознак, які сильно корелюють між собою виберіть для побудови моделей лише одну ознаку з кожної пари. Що таке тут має бути “сильна кореляція”?

Я залишила **revenue як основну фінансову змінну,** оскільки вона має найсильніший зв’язок з profit, а cost виключила через дуже високу кореляцію з revenue (0.98), щоб уникнути мультиколінеарності. Cost - викинули

1.3.4 Поділіть датасет на тренувальну та тестову вибірку (який поділ тут є раціональним?).

X - Це таблиця з ознаками, тобто вхідні дані моделі.
Y - Це цільова змінна, яку ми хочемо передбачати. - profit

```
-------------------- Поділ на train / test --------------
X_train: (776324, 4)
X_test: (194081, 4)
y_train: (776324,)
y_test: (194081,)

-------------------- Найбільш пов’язана ознака з profit -
revenue
```

ЗАВДАННЯ 2. ПОБУДОВА РЕГРЕСІЙНИХ МОДЕЛЕЙ

2.1 Проста лінійна регресія

2.1.1 Натренуйте модель лінійної регресії за допомогою класу `LinearRegression` модуля `linear_models` з бібліотеки Scikit-learn із загальними параметрами (загальна модель: коефіцієнти довільні, вільний член присутній у моделі) із використанням тренувальної вибірки. Обчисліть вбудовану метрику точності (метод .score) для тренувальної та тестової вибірки.

2.1.2 Обчисліть на додачу метрики для тренувальної та тестової вибірки. Mean absolute error. Mean squared logarithmic error. D^2 absolute error score. Виведіть їх одним датафреймом для порівняння разом із вбудованою метрикою точності із кроку 1.

```
-------------------- 2.1 Проста лінійна регресія --------------------

-------------------- Метрики простої лінійної регресії --------------------
              model dataset  score_R2       MAE      MSLE  D2_absolute_error
0  LinearRegression   train  0.931278  1.187720  0.016067           0.758055
1  LinearRegression    test  0.930889  1.188847  0.016071           0.757372
```

2.1.3 Побудуйте візуалізацію.

a. Діаграму розсіювання для тренувальної та тестової вибірки в одній системі координат, де тренувальна та тестова вибірка зображені різними кольорами. Причому:

   i. Вертикальна вісь - це цільова змінна.

   ii. Горизонтальна вісь - найбільш пов'язана із цільовою змінною, ознака із завдання 1.3.

b. Лінії, які утворюють прогнози різними кольорами/значками точок окремо для:

   i. тренувальної вибірки.

   ii. тестової вибірки.

c. Додайте легенду для діаграми.

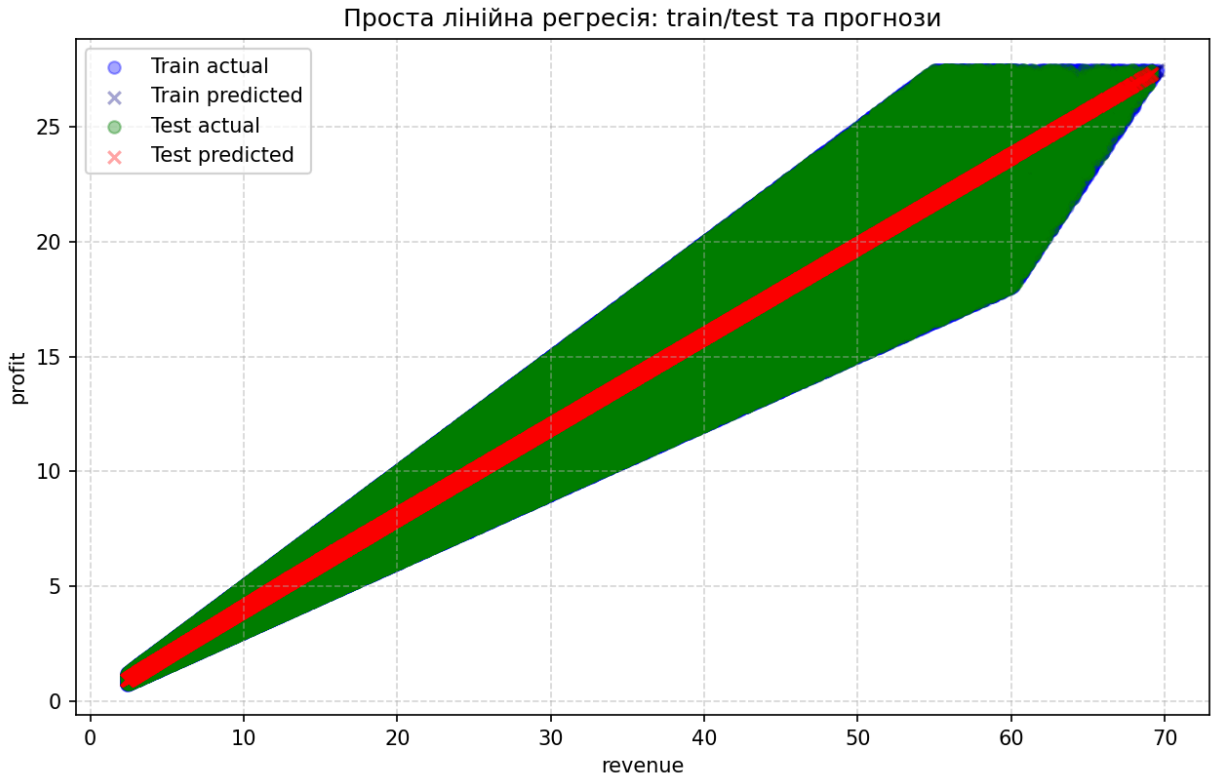

2.1.4

1. Аналіз метрик

Отримані значення метрик свідчать про високу якість побудованої моделі лінійної регресії.

- Значення $R^2 \approx 0.93$ як для train, так і для test вибірки означає, що модель пояснює приблизно 93% варіації цільової змінної (profit).
- Значення MAE ≈ 1.18 є досить малим, що вказує на незначну середню помилку прогнозу.
- Значення MSLE ≈ 0.016 також низьке, що означає відсутність великих відхилень у логарифмічному масштабі.
- Значення $D^2 \approx 0.75$ підтверджує хорошу якість прогнозу.

Метрики для train і test майже однакові, що свідчить про відсутність перенавчання (overfitting).

2. Аналіз графіка

З графіка залежності між `revenue` та `profit` видно чітку лінійну залежність.

- Точки (реальні значення) формують щільну лінійну структуру
- Прогнозовані значення (хрестики) майже співпадають із реальними
- Лінія прогнозу проходить посередині розподілу точок

Тож, модель дуже добре апроксимує реальні дані.

3. Інтерпретація залежності

Ознака `revenue` має сильний позитивний вплив на `profit`.

Це логічно, оскільки:

- прибуток напряму залежить від доходу
- між ними спостерігається майже лінійна залежність

4. Загальний висновок

Побудована модель лінійної регресії показала високу точність прогнозування та добре узагальнює дані. Вона не є перенавченою та коректно відображає залежність між змінними. Основним фактором, що впливає на прибуток, є дохід (`revenue`), що підтверджується як кореляційним аналізом, так і візуалізацією.

2.2 Проста лінійна регресія з перетворенням змінних

Виконайте завдання 2.2 із виконанням кроку 0.5 перед кроком 1.

0.5. Виконайте перетворення усіх змінних до нормального розподілу.

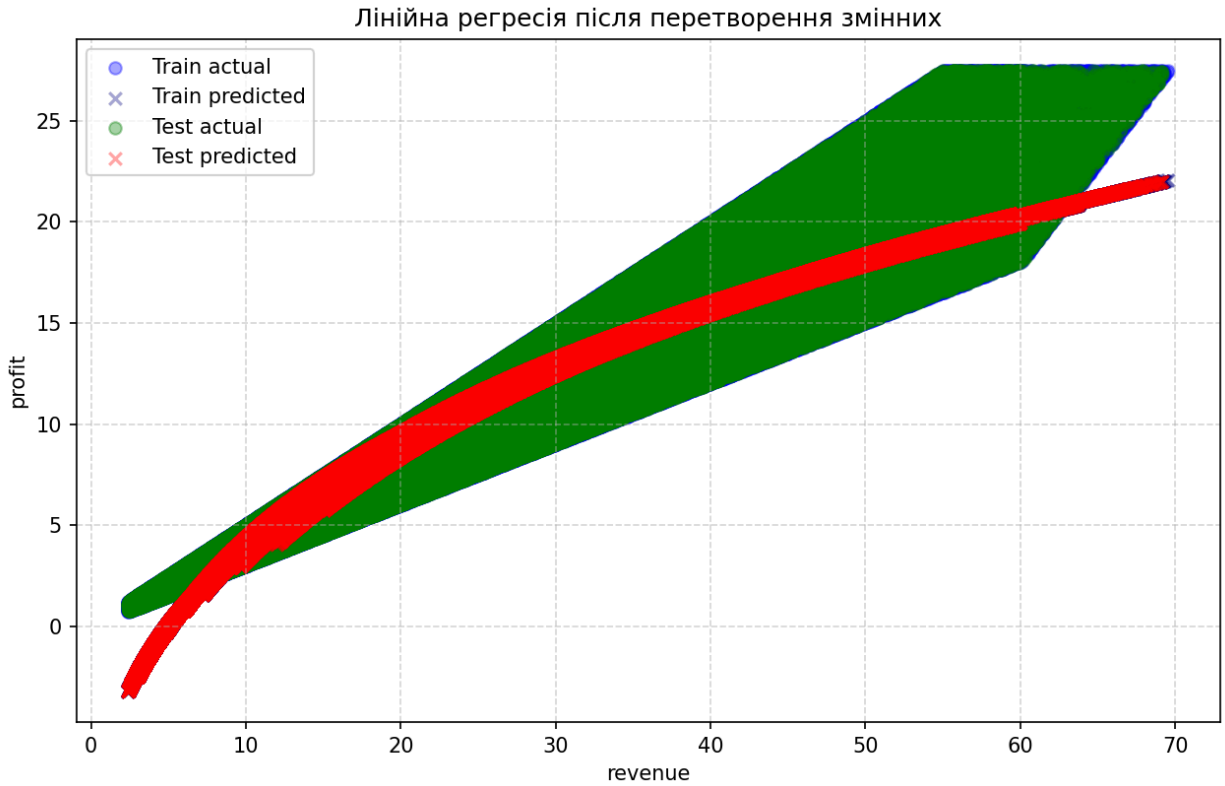

- червона лінія (prediction) вже не співпадає так добре з точками
- особливо внизу (малий revenue) є сильні відхилення
- навіть з'являються дивні значення (нижче 0)

Тож, модель стала менш точною і менш стабільною

```
-------------------- 2.2 Проста лінійна регресія з перетворенням змінних --------------------

-------------------- Метрики лінійної регресії після перетворення --------------------
                                 model dataset  score_R2       MAE      MSLE  D2_absolute_error
0  LinearRegression + PowerTransformer   train  0.887896  1.567566  0.080101           0.680678
1  LinearRegression + PowerTransformer    test  0.887603  1.566884  0.079321           0.680219
```

Модель після перетворення працює **гірше**, ніж базова.
Сталося це через те що у вихідних даних вже спостерігалась чітка лінійна залежність між змінними, і додаткове перетворення порушило цю структуру. Таким чином, у даному випадку застосування трансформації є недоцільним.

2.3 Гребенева регресія — це майже та сама лінійна регресія, але з додатковим “штрафом” за занадто великі коефіцієнти моделі.
У результаті побудови трьох Ridge-моделей з різними значеннями параметра alpha суттєвих відмінностей між метриками не виявлено. Це свідчить про те, що в даному наборі даних залежність між ознаками і цільовою змінною є стабільною та добре описується лінійною моделлю навіть при зміні сили регуляризації.

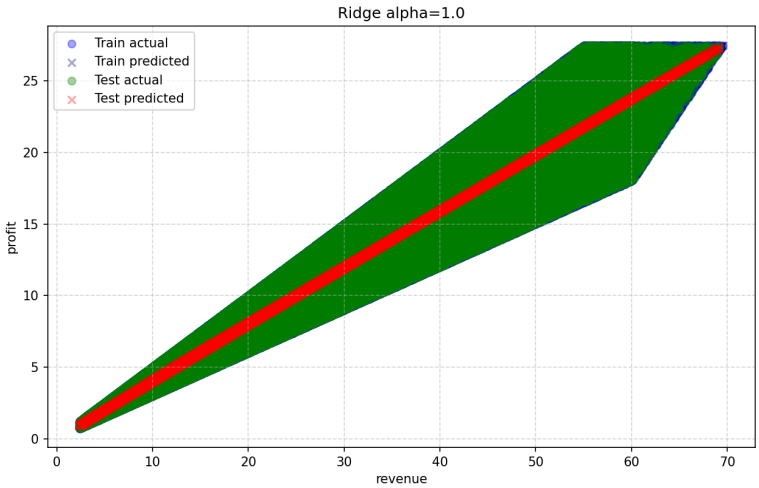

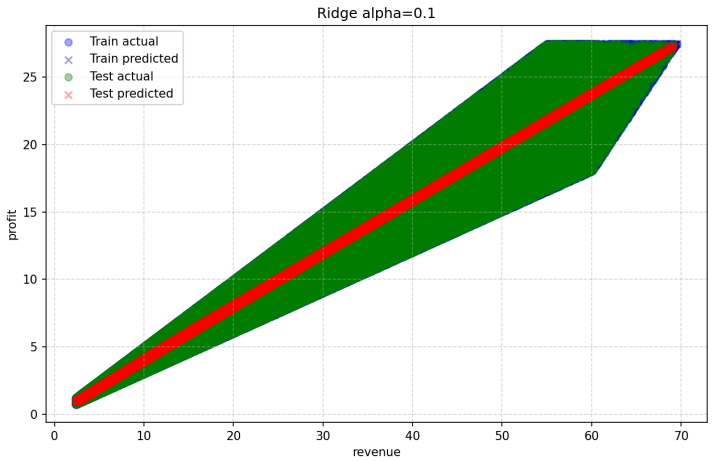

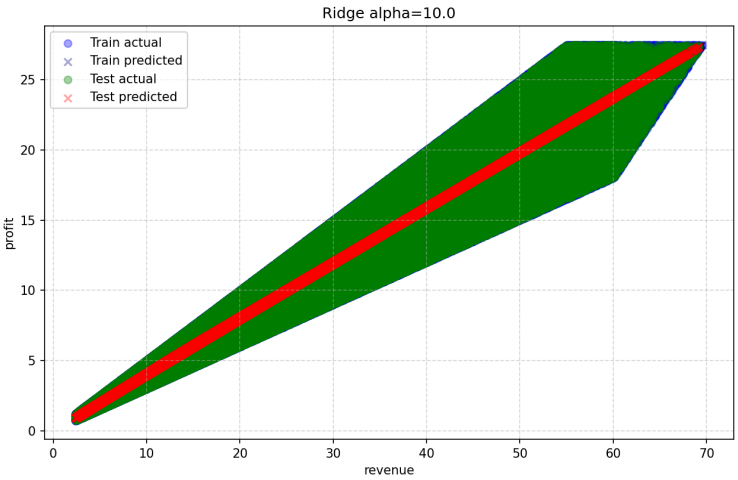


```
-------------------- Метрики гребеневої регресії --------------------
              model dataset  score_R2       MAE      MSLE  D2_absolute_error
0   Ridge alpha=1.0   train  0.931278  1.187720  0.016067           0.758055
1   Ridge alpha=1.0    test  0.930889  1.188847  0.016071           0.757372
2   Ridge alpha=0.1   train  0.931278  1.187720  0.016067           0.758055
3   Ridge alpha=0.1    test  0.930889  1.188847  0.016071           0.757372
4  Ridge alpha=10.0   train  0.931278  1.187720  0.016067           0.758055
5  Ridge alpha=10.0    test  0.930889  1.188847  0.016071           0.757372
C:\Users\DASHA\AppData\Local\Programs\Python\Python313\Lib\tkinter\__init__.py
```

2.4 Гребенева регресія з перетворенням змінних

У результаті застосування гребеневої регресії з перетворенням змінних було отримано нижчу якість моделі порівняно з простою лінійною регресією. Значення коефіцієнта детермінації (R^2) зменшилось з ~0.93 до ~0.88, а помилки MAE та MSLE збільшились.

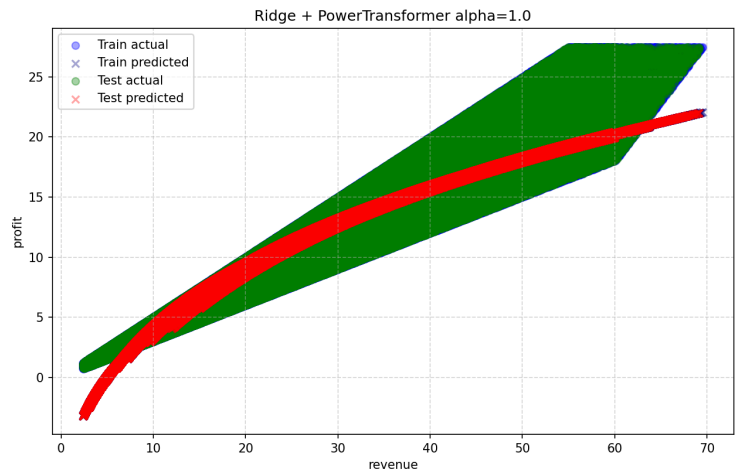

Це пояснюється тим, що вихідні дані вже мали лінійну залежність між ознаками, тому додаткове перетворення PowerTransformer порушило цю структуру. Використання Ridge-регресії також не дало суттєвого покращення, оскільки мультиколінеарність у даних не мала критичного впливу.

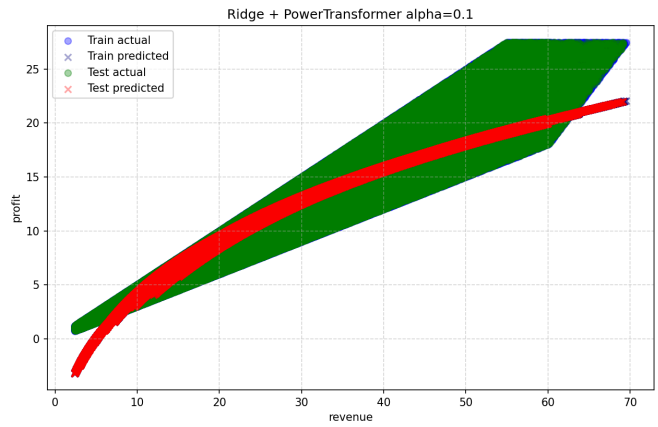

Отже, для даного набору даних найкращою виявилась проста лінійна регресія без додаткових перетворень.

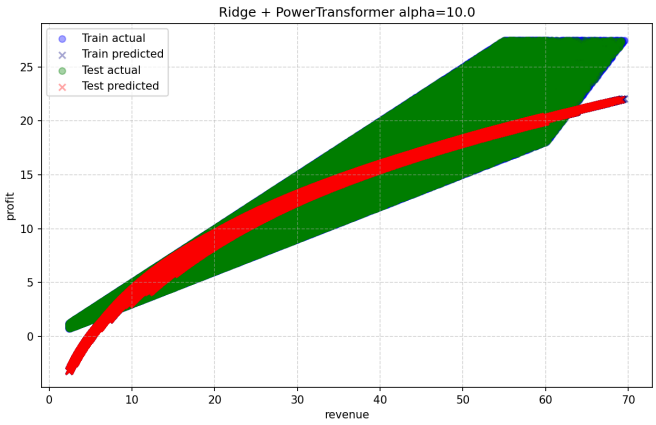


```
------------------- Метрики гребеневої регресії після перетворення --------------------
                  model dataset  score_R2       MAE      MSLE  D2_absolute_error
0   Ridge + PT alpha=1.0   train  0.887896  1.567563  0.080102           0.680679
1   Ridge + PT alpha=1.0    test  0.887603  1.566881  0.079322           0.680220
2   Ridge + PT alpha=0.1   train  0.887896  1.567565  0.080101           0.680678
3   Ridge + PT alpha=0.1    test  0.887603  1.566884  0.079321           0.680219
4  Ridge + PT alpha=10.0   train  0.887896  1.567537  0.080110           0.680684
5  Ridge + PT alpha=10.0    test  0.887603  1.566853  0.079330           0.680226
C:\Users\DASHA\AppData\Local\Programs\Python\Python313\Lib\tkinter\__init__.py:862: UserWar
```

2.5 Сукупне порівняння метрик з результатів експериментів

1. Порівняйте метрики отримані для всіх 4 етапів завдання 2 створивши для них спільний датафрейм з використанням бібліотеки `pandas`. За потреби можна використати мульти індекс.

```
------------------- Загальна таблиця метрик -------------------
                                 model dataset  score_R2       MAE      MSLE  D2_absolute_error
0                       LinearRegression   train  0.931278  1.187720  0.016067           0.758055
1                       LinearRegression    test  0.930889  1.188847  0.016071           0.757372
2   LinearRegression + PowerTransformer   train  0.887896  1.567566  0.080101           0.680678
3   LinearRegression + PowerTransformer    test  0.887603  1.566884  0.079321           0.680219
4                        Ridge alpha=1.0   train  0.931278  1.187720  0.016067           0.758055
5                        Ridge alpha=1.0    test  0.930889  1.188847  0.016071           0.757372
6                        Ridge alpha=0.1   train  0.931278  1.187720  0.016067           0.758055
7                        Ridge alpha=0.1    test  0.930889  1.188847  0.016071           0.757372
8                       Ridge alpha=10.0   train  0.931278  1.187720  0.016067           0.758055
9                       Ridge alpha=10.0    test  0.930889  1.188847  0.016071           0.757372
10                 Ridge + PT alpha=1.0   train  0.887896  1.567563  0.080102           0.680679
11                 Ridge + PT alpha=1.0    test  0.887603  1.566881  0.079322           0.680220
12                 Ridge + PT alpha=0.1   train  0.887896  1.567565  0.080101           0.680678
13                 Ridge + PT alpha=0.1    test  0.887603  1.566884  0.079321           0.680219
14                Ridge + PT alpha=10.0   train  0.887896  1.567537  0.080110           0.680684
15                Ridge + PT alpha=10.0    test  0.887603  1.566853  0.079330           0.680226
```

```
------------------- Таблиця метрик з мультиіндексом -------------------
                                          score_R2       MAE      MSLE  D2_absolute_error
model                                dataset
LinearRegression                     train    0.931278  1.187720  0.016067           0.758055
                                     test     0.930889  1.188847  0.016071           0.757372
LinearRegression + PowerTransformer train     0.887896  1.567566  0.080101           0.680678
                                     test     0.887603  1.566884  0.079321           0.680219
Ridge alpha=1.0                      train    0.931278  1.187720  0.016067           0.758055
                                     test     0.930889  1.188847  0.016071           0.757372
Ridge alpha=0.1                      train    0.931278  1.187720  0.016067           0.758055
                                     test     0.930889  1.188847  0.016071           0.757372
Ridge alpha=10.0                     train    0.931278  1.187720  0.016067           0.758055
                                     test     0.930889  1.188847  0.016071           0.757372
Ridge + PT alpha=1.0                 train    0.887896  1.567563  0.080102           0.680679
                                     test     0.887603  1.566881  0.079322           0.680220
Ridge + PT alpha=0.1                 train    0.887896  1.567565  0.080101           0.680678
                                     test     0.887603  1.566884  0.079321           0.680219
Ridge + PT alpha=10.0                train    0.887896  1.567537  0.080110           0.680684
                                     test     0.887603  1.566853  0.079330           0.680226
```

2. Розфарбуйте клітинки із значеннями метрик у кольоровій шкалі: червоний - менше, зелений - більше. Можна використати довільну градієнтну, або різнокольорову шкалу, що задовольняє цим умовам.

model	dataset	score_R2	MAE	MSLE	D2_absolute_error
LinearRegression	train	0.931278	1.187720	0.016067	0.758055
	test	0.930889	1.188847	0.016071	0.757372
LinearRegression + PowerTransformer	train	0.887896	1.567566	0.080101	0.680678
	test	0.887603	1.566884	0.079321	0.680219
Ridge alpha=1.0	train	0.931278	1.187720	0.016067	0.758055
	test	0.930889	1.188847	0.016071	0.757372
Ridge alpha=0.1	train	0.931278	1.187720	0.016067	0.758055
	test	0.930889	1.188847	0.016071	0.757372
Ridge alpha=10.0	train	0.931278	1.187720	0.016067	0.758055
	test	0.930889	1.188847	0.016071	0.757372
Ridge + PT alpha=1.0	train	0.887896	1.567563	0.080102	0.680679
	test	0.887603	1.566881	0.079322	0.680220
Ridge + PT alpha=0.1	train	0.887896	1.567565	0.080101	0.680678
	test	0.887603	1.566884	0.079321	0.680219
Ridge + PT alpha=10.0	train	0.887896	1.567537	0.080110	0.680684
	test	0.887603	1.566853	0.079330	0.680226

1. Загальна таблиця метрик - це просто всі результати підряд, без спеціального групування.

2. Таблиця з мультиіндексом - це ті самі результати, але вже зручніше оформлені:
перший індекс — модель
другий індекс — dataset (train або test)

3. Кольорова таблиця - це та сама таблиця, але вже з візуальним підсвічуванням значень.

Що означають самі метрики

score_R2 - коефіцієнт детермінації. Показує, наскільки добре модель пояснює залежність між ознаками і цільовою змінною.
ближче до 1 → краще
ближче до 0 → гірше
У нас: для кращих моделей ≈ 0.93. для слабших ≈ 0.887
Тож, кращі моделі пояснюють приблизно 93% варіації profit, слабші — приблизно 88.7%

MAE - Середня абсолютна помилка. Показує: на скільки в середньому модель помиляється у прогнозі. Чим менше, тим краще.
У нас: кращі моделі: ≈ 1.18, слабші моделі: ≈ 1.56. Тобто слабші моделі помиляються більше.

MSLE - Середньоквадратична логарифмічна помилка. Вона теж показує похибку, але в логарифмічному вигляді. Чим менше, тим краще.
У нас: кращі моделі: ≈ 0.016, слабші: ≈ 0.079–0.080. Це вже досить помітна різниця.

D2_absolute_error - Ще одна метрика якості моделі. Чим ближче до 1, тим краще.
У нас: кращі моделі: ≈ 0.758, слабші: ≈ 0.680. Тобто тут теж видно, що перша група моделей працює краще.

У мене фактично всі моделі розпалися на 2 великі групи.

Група 1 — найкращі моделі:
LinearRegression
Ridge alpha=1.0
Ridge alpha=0.1
Ridge alpha=10.0

У всіх них:
score_R2 ≈ 0.931
MAE ≈ 1.188
MSLE ≈ 0.016
D2_absolute_error ≈ 0.758
Усі ці моделі дали практично однаковий результат.

Група 2 — слабші моделі:
LinearRegression + PowerTransformer
Ridge + PT alpha=1.0
Ridge + PT alpha=0.1
Ridge + PT alpha=10.0

У всіх них:
score_R2 ≈ 0.887
MAE ≈ 1.567
MSLE ≈ 0.079–0.080

D2_absolute_error ≈ 0.680
Усі моделі після PowerTransformer стали гіршими.

Головне
Висновок №1
Ridge не покращив результат порівняно зі звичайною лінійною регресією
Це видно з того, що:
LinearRegression
Ridge alpha=1.0
Ridge alpha=0.1
Ridge alpha=10.0
дали однакові метрики.
Це означає, щу у наборі даних: задача вже дуже добре описується простою лінійною моделлю; регуляризація Ridge не дала виграшу; зміна alpha нічого суттєво не змінила.

Висновок №2
PowerTransformer погіршив результат
Це видно дуже чітко:
Було без перетворення:
R2 ≈ 0.93
MAE ≈ 1.18
Стало після перетворення:
R2 ≈ 0.887
MAE ≈ 1.56
Це показує, що у даних уже була хороша лінійна залежність між ознаками і profit.
Після перетворення ця структура стала менш зручною для моделі.
Трансформація тут не допомогла, а навпаки — зіпсувала якість прогнозу.

Висновок №3
Train і test майже однакові
Це дуже хороший знак.
Наприклад:
Для LinearRegression:
train 0.931278
test 0.930889
Різниця мінімальна, тож модель: не перенавчилась; не “запам’ятала” тільки train; працює стабільно і на нових даних.

Підсумок

Найкращі моделі:
LinearRegression
усі Ridge без трансформації
Гірші моделі:
LinearRegression + PowerTransformer
усі Ridge + PowerTransformer
Отже:
найкращим виявився базовий варіант без трансформації
Ridge не дав переваги
PowerTransformer погіршив якість